

W 1

# 網路爬蟲概論與開發環境建置

工具 · VS Code · Python

吳彥霖 博士

Python 爬蟲實務應用 · 第 1 週 · 09/15

## 節 1

# 網路爬蟲概論

# 什麼是網路爬蟲

一種自動**瀏覽全球資訊網**的程式(網路機器人)，  
會依規則自動  
**走訪網頁、抓取內容**。

在這門課，我們用它把散落在網頁上的資料，**自動蒐集成可分析的資料表**。

蒐集市場行情 ( 比價 )

匯集輿情文本 ( 看輿情 )

建立研究資料集 ( 做分析 )

... 還有更多


# 資料科學流程：CRISP-DM

跨產業資料探勘標準流程



流程可反覆迭代；這門課將聚焦在「爬取 → 清理整理 → 分析 → 視覺化 → 解讀」。

# 資料應用的過程



「問題定義」->「資料蒐集」-- 爬蟲  
「資料清理」->「結果解讀」-- 應用

# 資料從哪來

網頁

解析 HTML

API

官方介面回傳

開放資料

政府 / 機構釋出

優先用「開放資料 / 官方 API」 - 合法、穩定、乾淨

# 抓資料，不只一種方法

程式語言

RPA

AI Agent

## 網頁改版，三種方法都要重寫嗎？

不是。三種方法的應對，不盡相同。

真正的關鍵，不是「有沒有改版」，而是——

改到的是「外觀位置」，還是「網頁結構」？

# 兩種「改版」，難度天差地遠

## 改外觀 / 位置

換配色、字體、間距  
版面挪動、插入廣告

← 佔多數

## 改網頁結構

HTML 標籤、class / id 換掉  
DOM 重新排版

較少見 →

# 同樣改版，三種方法差在哪

|          | 只改外觀 / 位置         | 改網頁結構       |
|----------|-------------------|-------------|
| RPA      | ✗ 會壞 ( 綁畫面 / 座標 ) | ✗ 會壞 → 常需重建 |
| Python   | ✓ 幾乎不受影響          | △ 修改選擇器     |
| AI Agent | ~ 自動適應            | ~ 自動適應，但須驗證 |

改版時，Python 動最少、又動得明白：外觀改不動它、結構改也只是小修，而且我們看得懂改在哪。

RPA 綁 UI 最脆弱；AI Agent 看似最耐改版，卻是黑箱——抓錯了，我們可能會渾然不知。

解析原理：Python 靠標籤 / CSS 選擇器 / XPath 定位；RPA 綁 UI 畫面；AI Agent 每次由 LLM 重新判讀

# 為什麼要學 Python 爬蟲


## 一條龍整合

爬取 → pandas → 視覺化 → 部署，都在同一語言

## 看懂才驗得了 AI

RPA、AI Agent 都在生成程式；懂程式才駕馭得了

# AI 幫我們爬，驗證得了嗎



影片來源：[The AI Journal](#)

當 AI 幫我們把程式建好、我們卻不知道它為什麼會動 – 我們只能不要去改它。

AI Agent 每次都「重新判斷」 – 看似能自動適應改版，卻不保證抓對、也難以驗證。

看不懂它怎麼運作，就驗不了它抓對沒 – 這，就是要學 Python 爬蟲的理由。

# 爬得到，不代表爬得對

✓ 遵守 robots.txt 與使用條款

✓ 合理頻率、節流不擾站

✓ 尊重個資與著作權

✓ 優先用開放資料 / 官方 API

節 2

# 開發環境建置

# 我們的工具箱

VS Code

編輯器

Python

直譯器

# 為什麼要有本機環境

## 能掌控

版本、套件都在你手上

## 能重現

專題要能在別人電腦重跑

# 安裝與驗證，七個步驟




逐步操作（含實機截圖）請看 [《W1\\_開發環境建置\\_操作手順》](#)

### 節 3

# 我們的第一支爬蟲

# 一支爬蟲，四個步驟





問題定義 → 資料蒐集

# 第一支爬蟲

pandas 的 `read_html` 一行抓表格

# Demo：抓一張表



[illegible]

# 為什麼可以抓維基百科

維基百科採 **CC BY-SA** 授權 - 可自由使用，需標示來源

養成習慣：抓之前先問「這個資料，我有權用嗎？」

# 認識 CC 授權 ( 創用 CC )

四個要素的組合，決定我們能怎麼用別人的作品

**BY**

姓名標示

標示原作者 / 來源

**SA**

相同方式分享

衍生作品需同授權

**NC**

非商業

不得商業用途

**ND**

禁止改作

不得修改作品

維基百科 = **CC BY-SA**：可自由使用（甚至商用），但需「標示來源」，且衍生作品要「以相同授權釋出」。

# CC 授權：白話怎麼用、怎麼看

## ① 使用原則

- 你幾乎什麼都能做——自由使用、複製、散布、修改，連商用都可以
- 兩個條件——BY 標示來源 · SA 相同分享
- 一條紅線——不能再加額外限制，擋別人用授權允許的事

## ② 怎麼讀 CC 標示

格式：CC + 要素字母 + 版本

例：CC BY-SA 4.0

BY → 要標名 SA → 要相同分享

沒 NC → 可商用 沒 ND → 可改作

心法：看字母，就知道能不能商用、能不能改

抓維基百科 → 用在報告 / 專題要「標示來源」；把整理後的資料集再公開 → 用「相同授權」釋出。

依 Creative Commons 官方通俗版 ( CC BY-SA 4.0 Deed )

今天，我們學到了什麼？

下週見 · Python 爬蟲實務應用