W 6

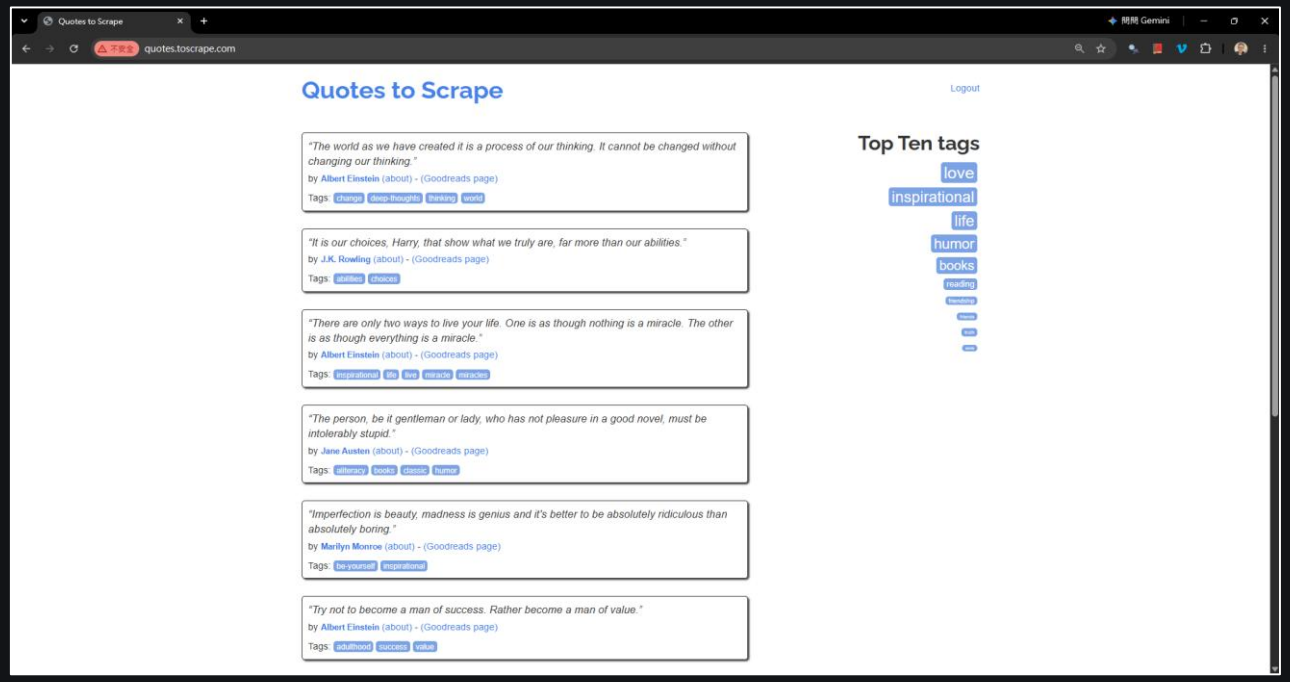
分頁爬取、資料儲存與爬蟲規範

翻頁與禮貌爬取 · SQLite 資料庫 · robots.txt 與法規

吳彥霖 博士

Python 爬蟲實務應用 · 第 6 週 · 10/20

課堂練習 - 1



http://quotes.toscrape.com/

- 爬取 Quotes to Scrape 網站中所有的名言，且存成 quotes_all.csv 。
  欄位名稱：page、quote、author、tags
- 另外，利用 logging 記錄爬取過程，記錄每頁抓到幾句名言，將 log 資訊存成 week_06_ex1_Quotes_all.log。

三節課，三件事

節 1

分頁爬取

- 翻頁模式 + 停止條件
- time.sleep 節流
- Session 與 Cookie（登入示範）

節 2

爬蟲規範

- robots.txt 實查與 robotparser

節 3

SQLite 資料儲存

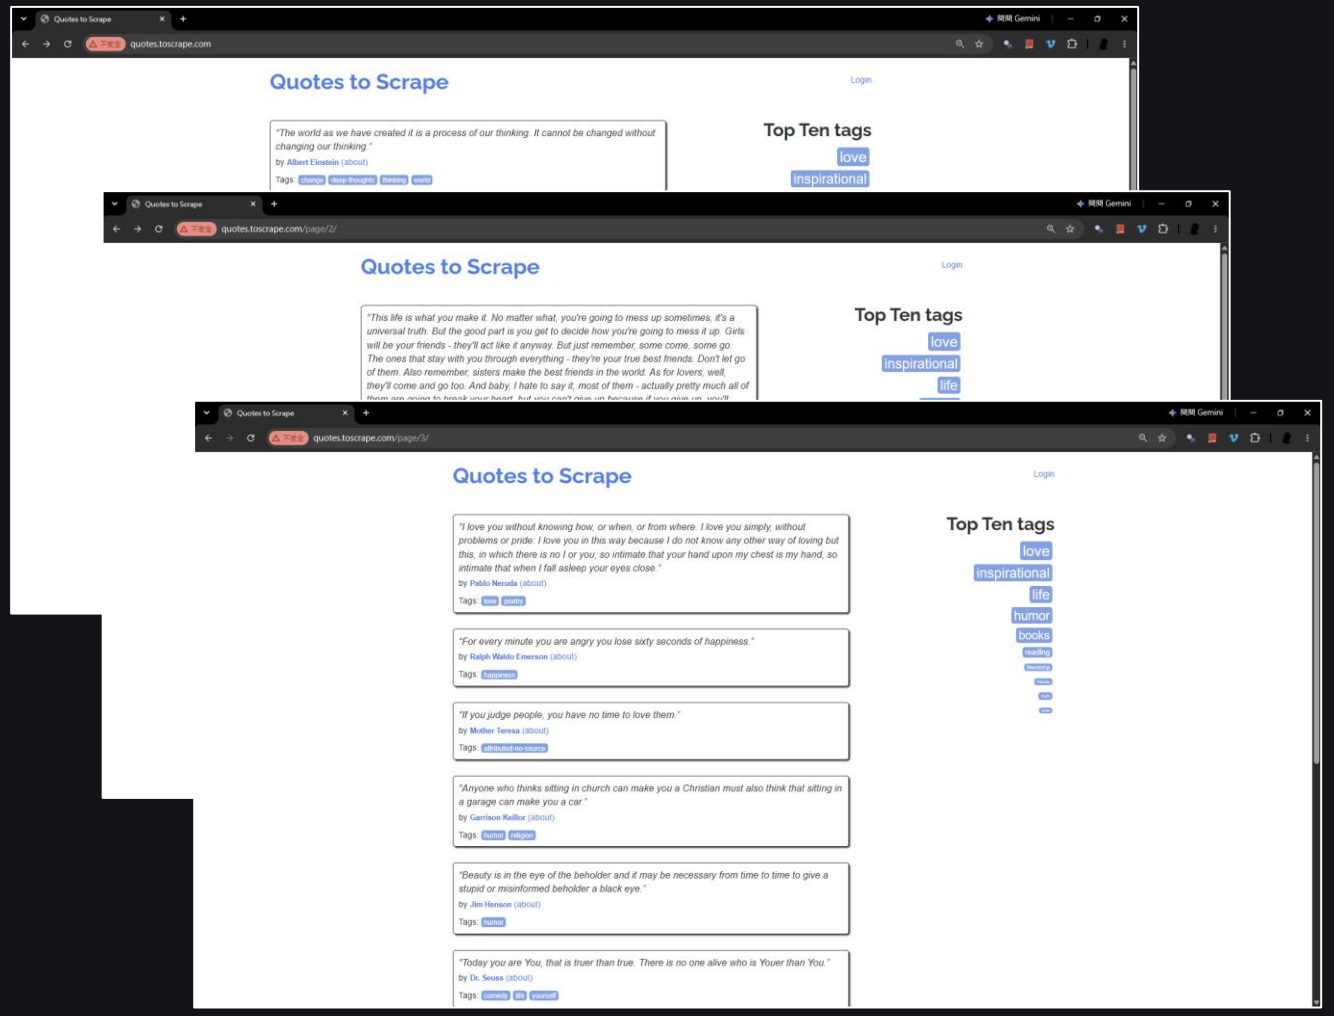
- 為什麼不只用 CSV
- 連線、建立、讀取

節 1

分頁爬取

Pagination

分頁的模式 – 網址可推算



- 網址帶頁碼(或位移量)

http://quotes.toscrape.com/

↓

http://quotes.toscrape.com/page/2/

↓

http://quotes.toscrape.com/page/3/

↓

.....

分頁的模式 – 網址可推算



- 網址帶頁碼(或位移量)

https://www.ithome.com.tw/latest

↓

https://www.ithome.com.tw/latest?page=1

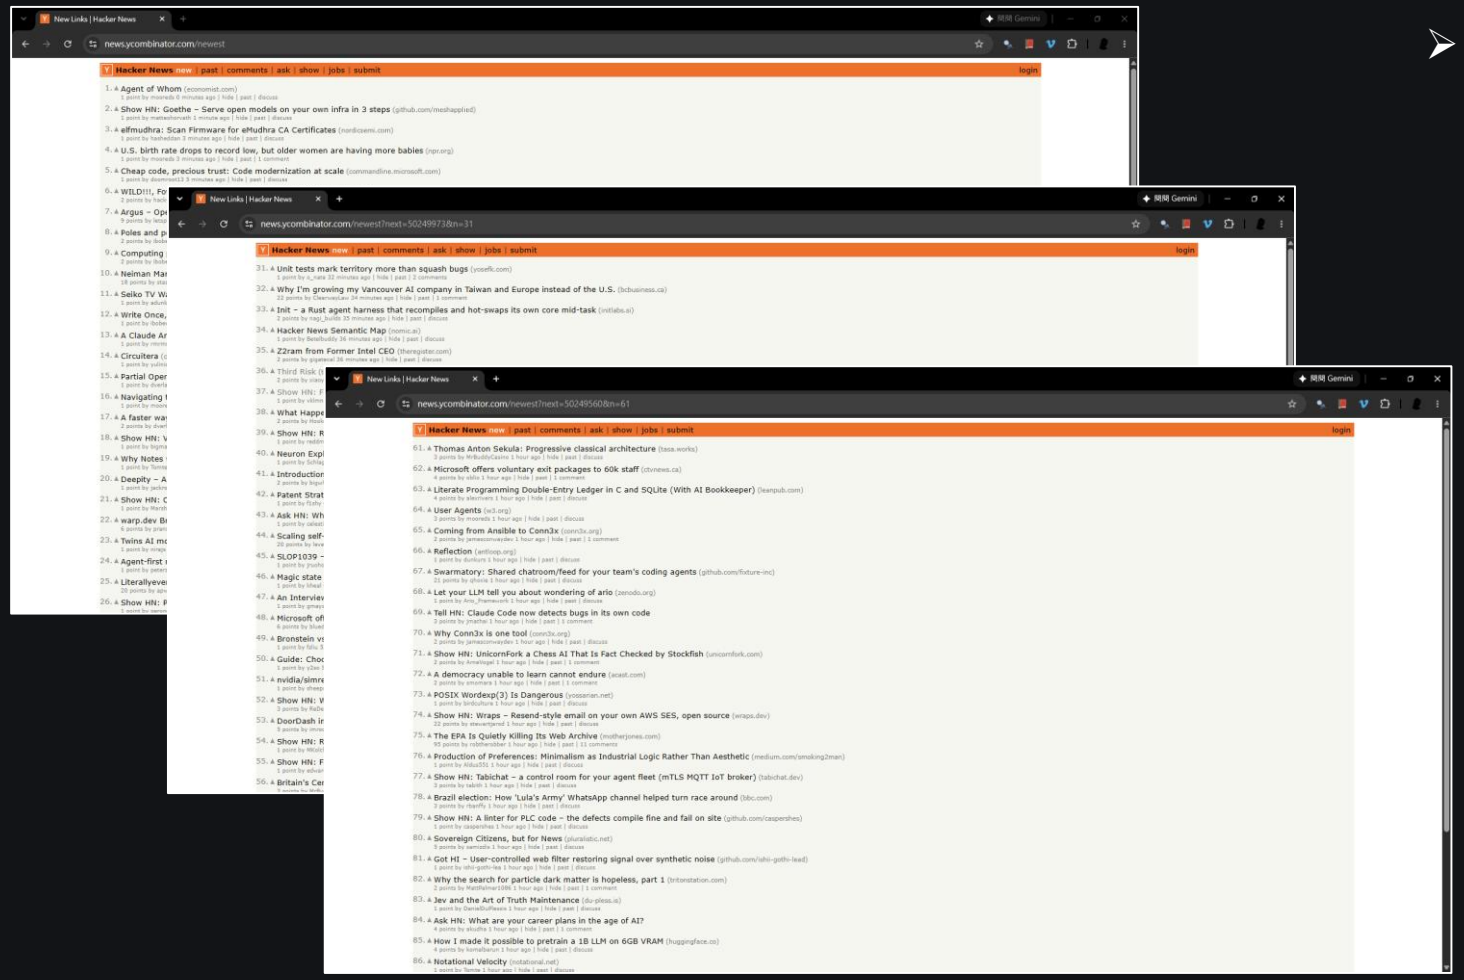
↓

https://www.ithome.com.tw/latest?page=2

↓

.....

分頁的模式 – 網址帶游標



- 網址帶頁碼(或位移量)

https://news.ycombinator.com/newest

↓

https://news.ycombinator.com/newest?next=50249973&n=31

↓

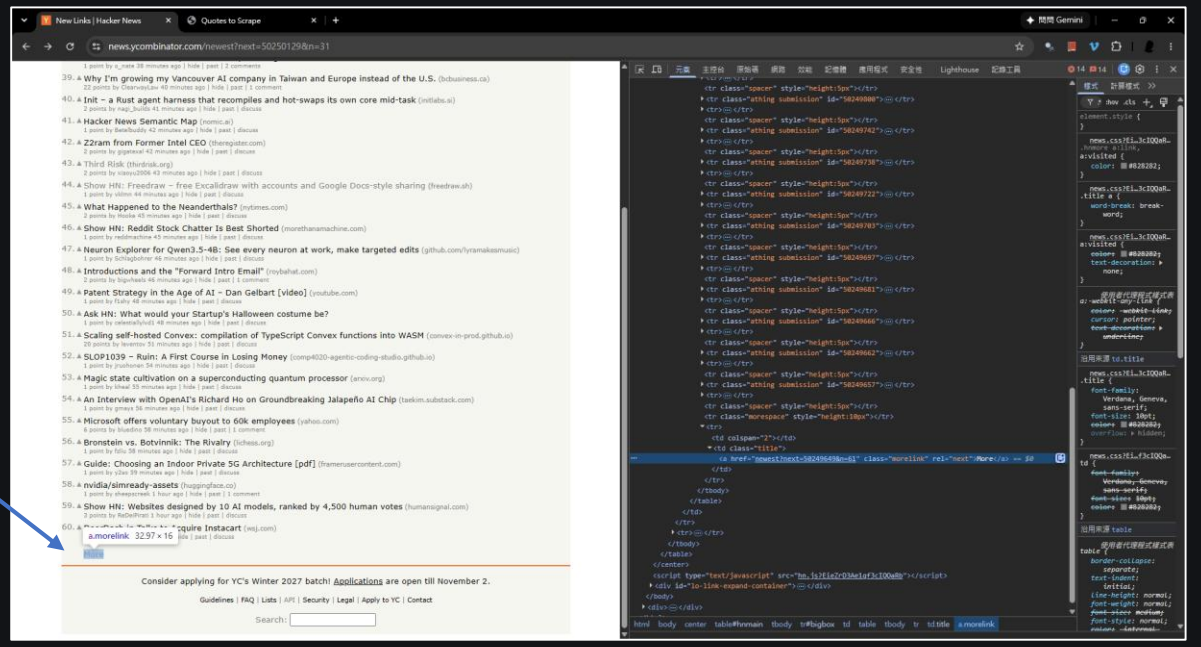
https://news.ycombinator.com/newest?next=50249560&n=61

↓

.....

分頁的爬取方法

模式	程式寫法
網址可推算	while 迴圈逐頁爬取
網址帶游標	先找連結的 href，再 urljoin 拼接出完整的網址



requests.Session 連續造訪

- 目的 : 用來在多次 HTTP 請求之間**保持跨請求的狀態**

功能	requests.get()	Session
headers	每次請求獨立	設定一次，之後自動帶
cookie	不保存	自動保存、自動帶回
連線	每次重新建立	重複使用，比較快

```
BASE_URL = " .... "
HEADERS = {"User-Agent": "..."}

session = requests.Session()
session.headers.update(HEADERS)

for page in range(1, 11):
    resp = session.get(f"{BASE_URL}/page/{page}/", timeout=10)
    ...
```

概念　同一網站多頁爬取，自動記錄 session 期間所存的cookie，讓伺服器保留這段 session 的狀態態。

Cookie 與登入

1
GET /login
伺服器發 session cookie
+ 表單藏一個 csrf_token

➜

2
POST /login
送出帳密 + csrf_token
(cookie 要一起帶回)

➜

3
比對配對
token 與 cookie 對得上
→ 登入成功

➜

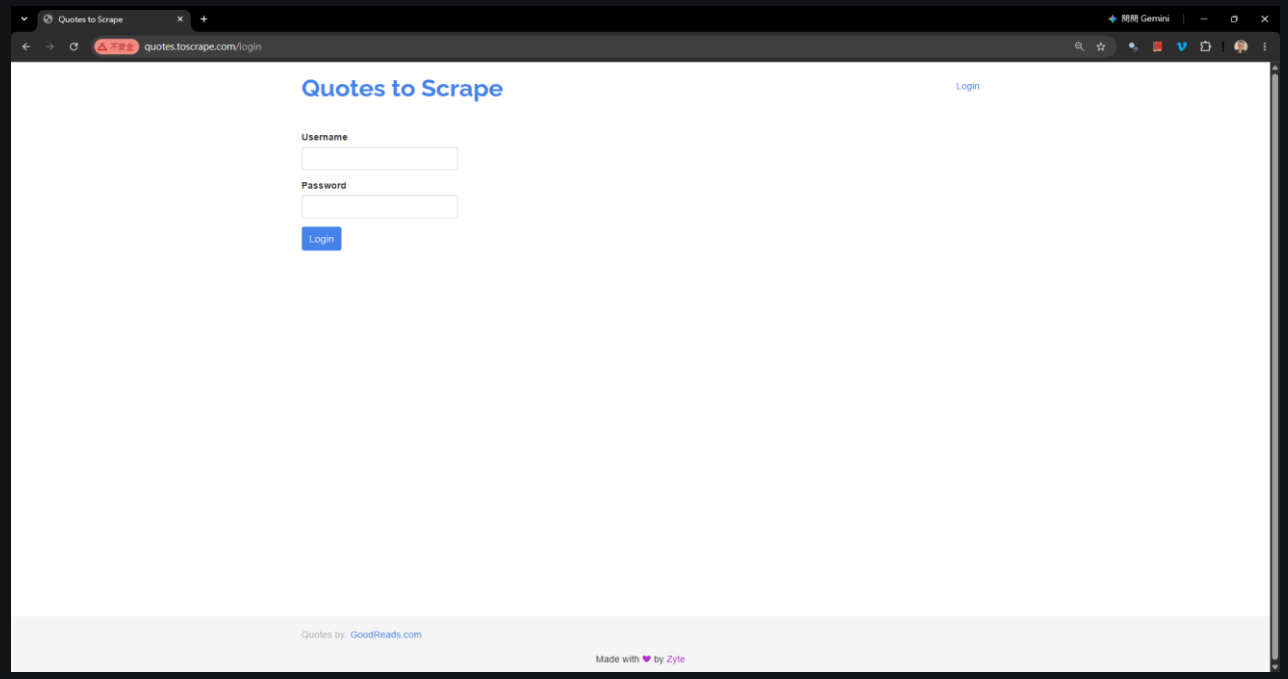
4
之後的請求
帶著 cookie
→ 看到登入後的內容

Session 的角色：第 1 步拿到的 cookie，第 2、4 步自動帶回去。

CSRF Token ? 全名為 Cross-Site Request Forgery Token 跨站請求偽造權杖，是一段由伺服器產生一組獨一無二，且用來驗證網頁請求是否為使用者本人主動發出的隨機字串。

> **概念** Cookie 是伺服器發給我們的號碼牌；Session 幫我們保管號碼牌。

課堂練習 - 2



http://quotes.toscrape.com/login

- 登入 Quotes to Scrape 網站中，爬取第一頁所有的名言，且存成 quotes_all.csv 。
  欄位名稱：page、quote、author、tags
- 另外，利用 logging 記錄爬取過程，記錄每頁抓到幾句名言，將 log 資訊存成 week_06_ex2_Quotes_login.log。

while 迴圈的停止條件?

停止訊號	實際狀況	狀態碼
這一頁沒有資料	quotes 第 11 頁： "No quotes found!"	200
沒有下一頁連結	quotes 第 10 頁、 books 第 50 頁	200
網頁不存在	books page-51.html	404

```
page = 1
while page <= MAX_PAGES:        # 保險絲
    soup = get_soup(f"{BASE}/page/{page}/")
    cards = soup.select("div.quote")
    if not cards:               # 停止條件
        break
    ...
    page += 1
    time.sleep(1)
```

概念　狀態碼 200 不一定代表有資料 - 停止條件也要檢視爬取的內容。

MAX_PAGES 怎麼定？

	停止條件	MAX_PAGES
角色	正常結束	保險絲（最後防線）
預期	每次都由它結束	正常永遠不該碰到
觸發代表	資料抓完了	**出狀況了，要去查**

week_06_exercise_1.py（節錄）

```
if page > MAX_PAGES:     # 不是沒資料而停，是保險絲斷了
    logger.warning("達到 MAX_PAGES=%s，資料可能沒抓完",
                   MAX_PAGES)
```

① 先估總頁數

頁面寫出總頁數：books「Page 1 of 50」
總筆數 ÷ 每頁筆數：1000 ÷ 20 = 50

② 設成估計值 × 2 左右

quotes 10 頁 → 練習設 50；books 50 頁 → 作業設 100
碰到上限 = 多抓了一倍 → 一定有問題

③ 估不出來（如最新列表）→ 用預算定

需求：只要近 7 天？先算一天幾頁
時間：頁數 × 間隔（iThome Crawl-delay 10 秒，100 頁 ≈ 17 分鐘）

概念 MAX_PAGES 是保險絲，不是預計頁數：先估再乘 2；碰到上限要寫 WARNING，不能安靜結束。

今天，我們學到了什麼？

下週見 · Python 爬蟲實務應用