W 6

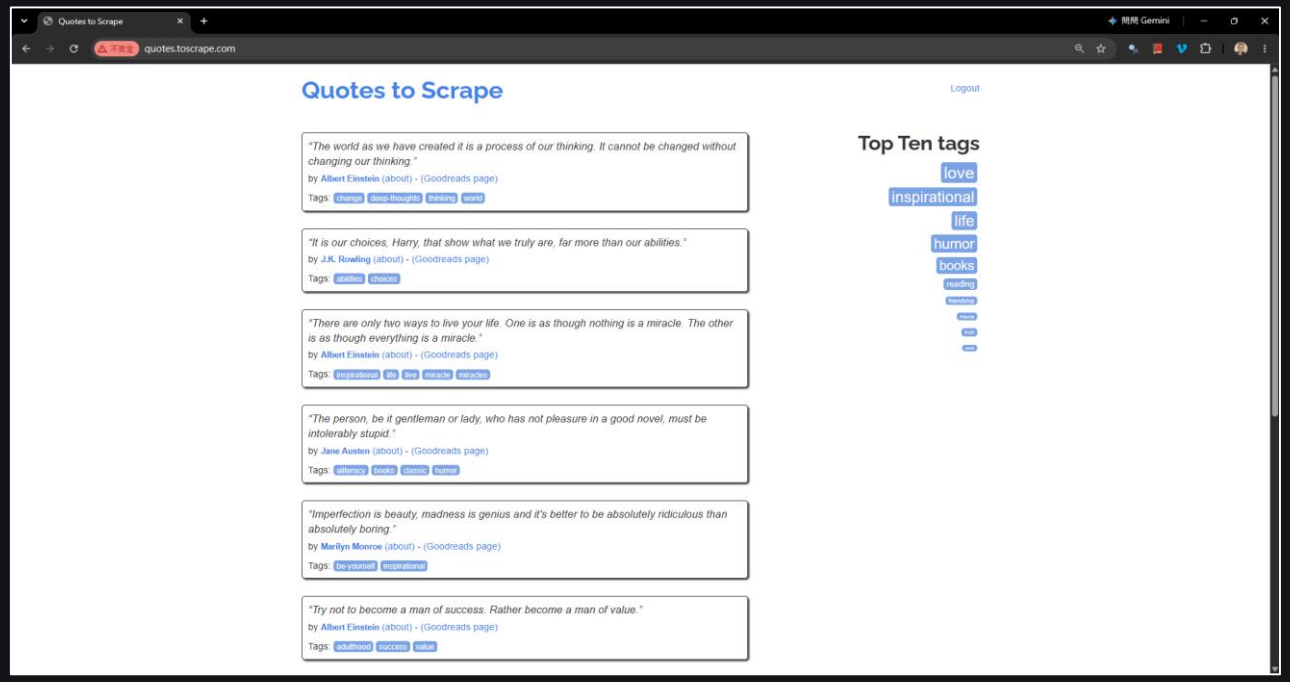
分頁爬取、資料儲存與爬蟲規範

翻頁與禮貌爬取 · SQLite 資料庫 · robots.txt 與法規

吳彥霖 博士

Python 爬蟲實務應用 · 第 6 週 · 10/20

課堂練習 - 1



http://quotes.toscrape.com/

- 爬取 Quotes to Scrape 網站中所有的名言，且存成 quotes_all.csv 。
  欄位名稱：page、quote、author、tags
- 另外，利用 logging 記錄爬取過程，記錄每頁抓到幾句名言，將 log 資訊存成 week_06_ex1_Quotes_all.log。

三節課，三件事

節 1

分頁爬取

- 翻頁模式 + 停止條件
- time.sleep 節流
- Session 與 Cookie（登入示範）

節 2

爬蟲規範

- robots.txt 實查與 robotparser

節 3

SQLite 資料儲存

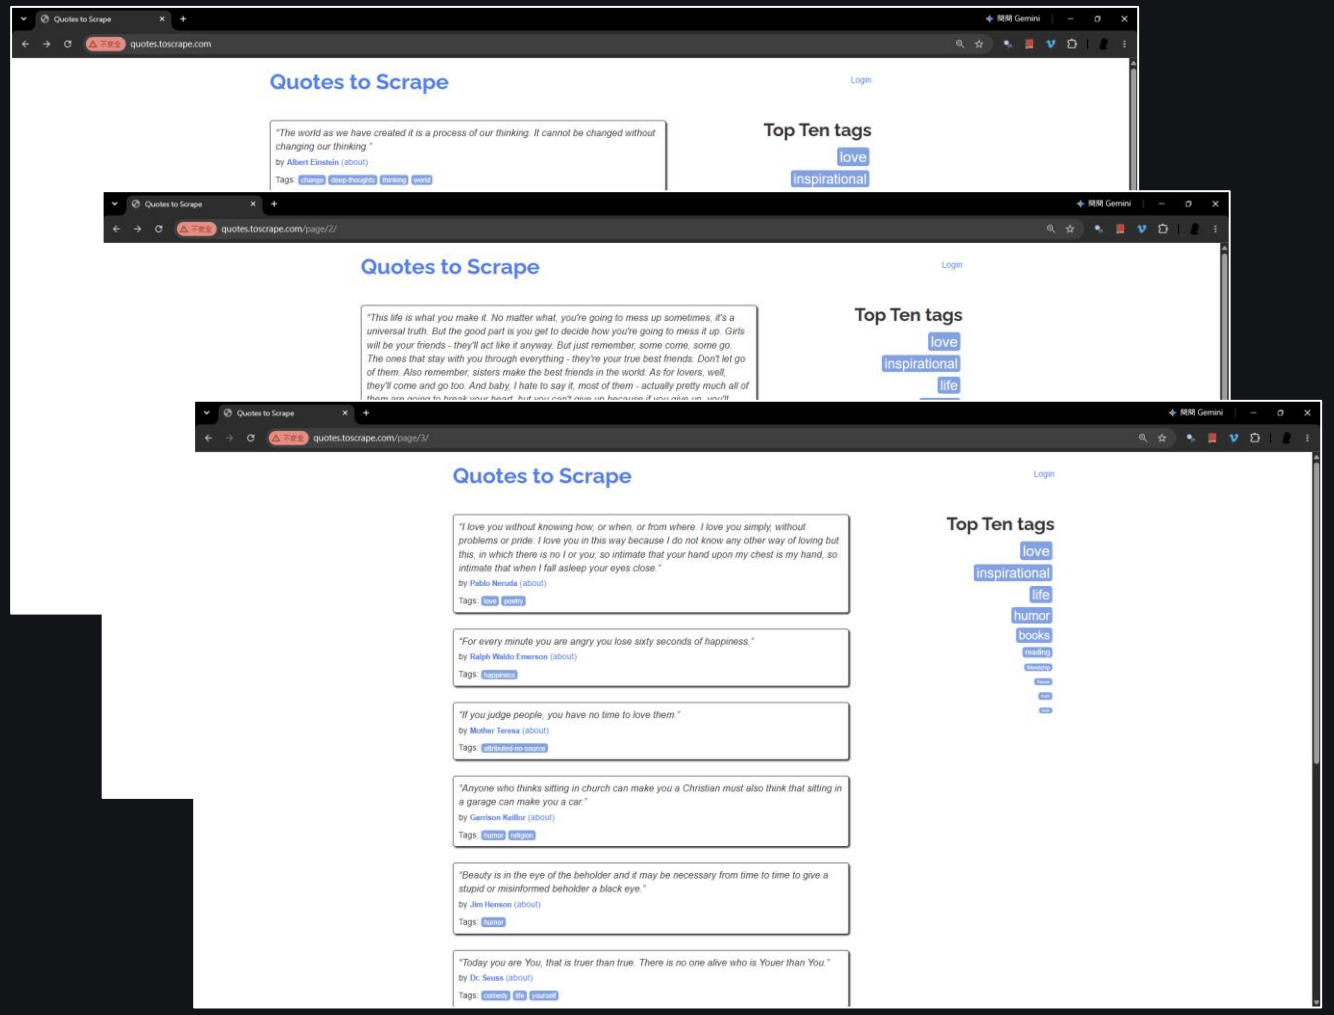
- 為什麼不只用 CSV
- 連線、建立、讀取

節 1

分頁爬取

Pagination

分頁的模式 – 網址可推算



- 網址帶頁碼(或位移量)

http://quotes.toscrape.com/

↓

http://quotes.toscrape.com/page/2/

↓

http://quotes.toscrape.com/page/3/

↓

.....

分頁的模式 – 網址可推算



- 網址帶頁碼(或位移量)

https://www.ithome.com.tw/latest

↓

https://www.ithome.com.tw/latest?page=1

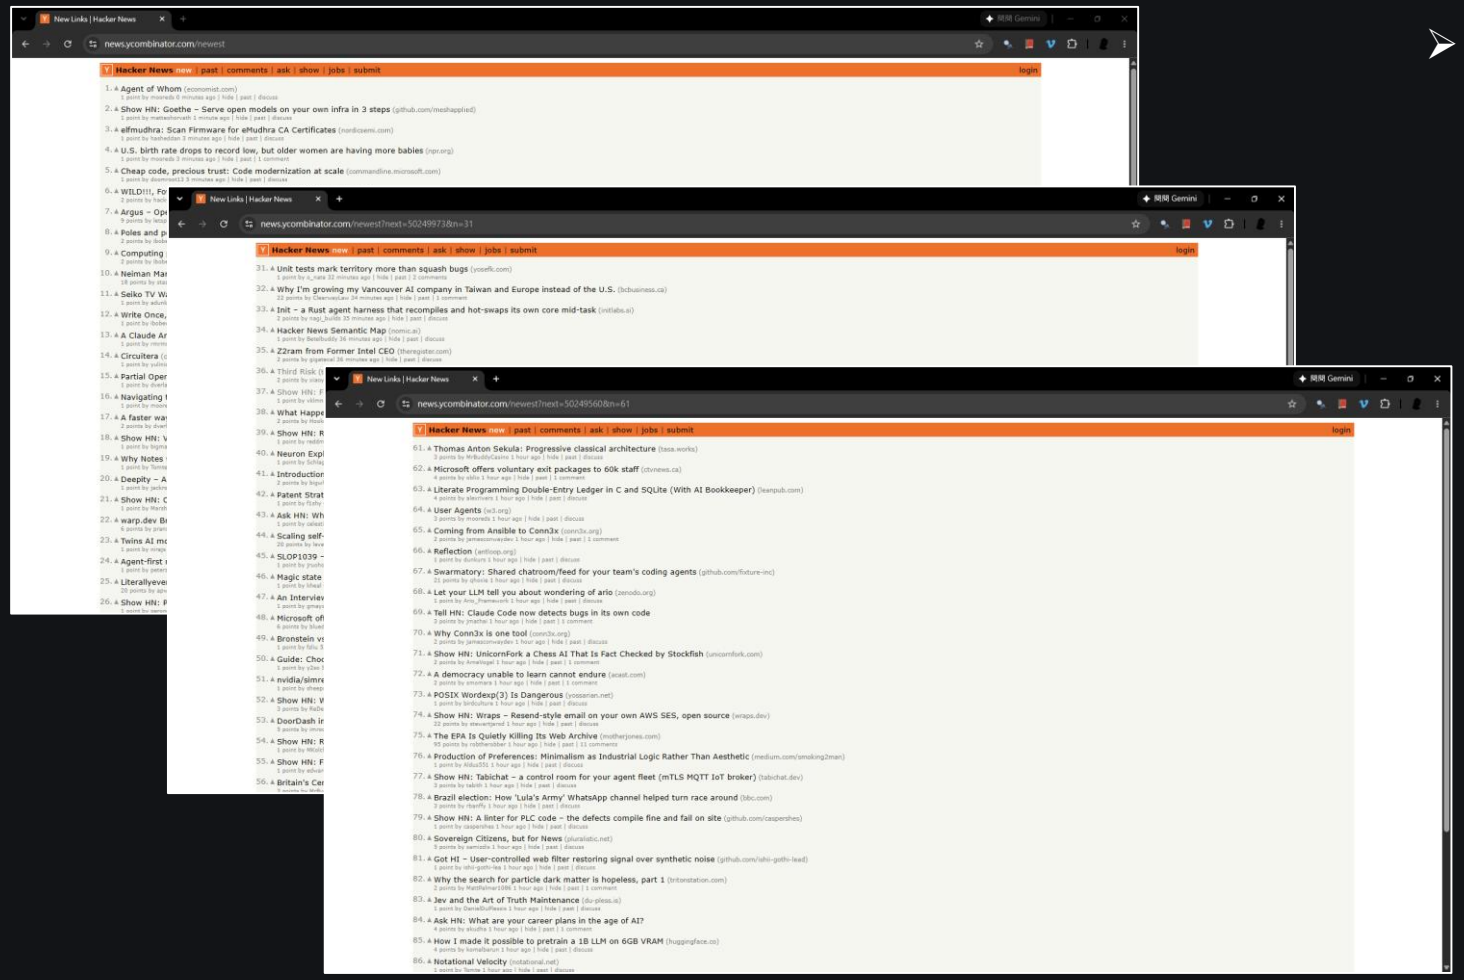
↓

https://www.ithome.com.tw/latest?page=2

↓

……

分頁的模式 – 網址帶游標



- 網址帶頁碼(或位移量)

https://news.ycombinator.com/newest

↓

https://news.ycombinator.com/newest?next=50249973&n=31

↓

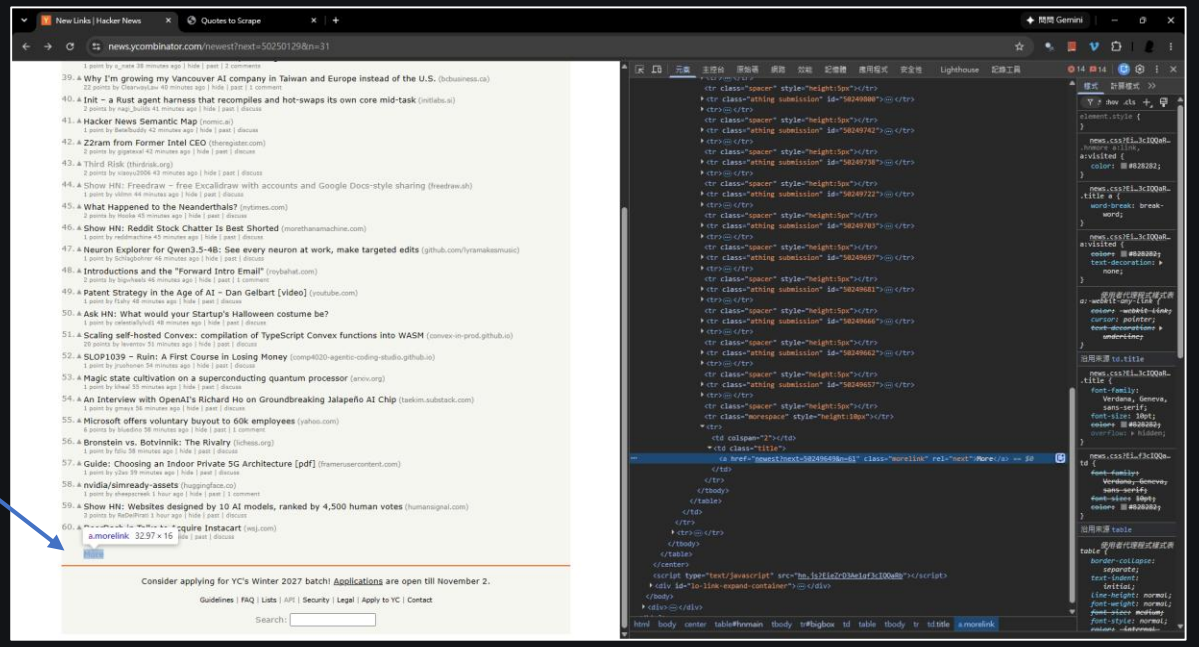
https://news.ycombinator.com/newest?next=50249560&n=61

↓

.....

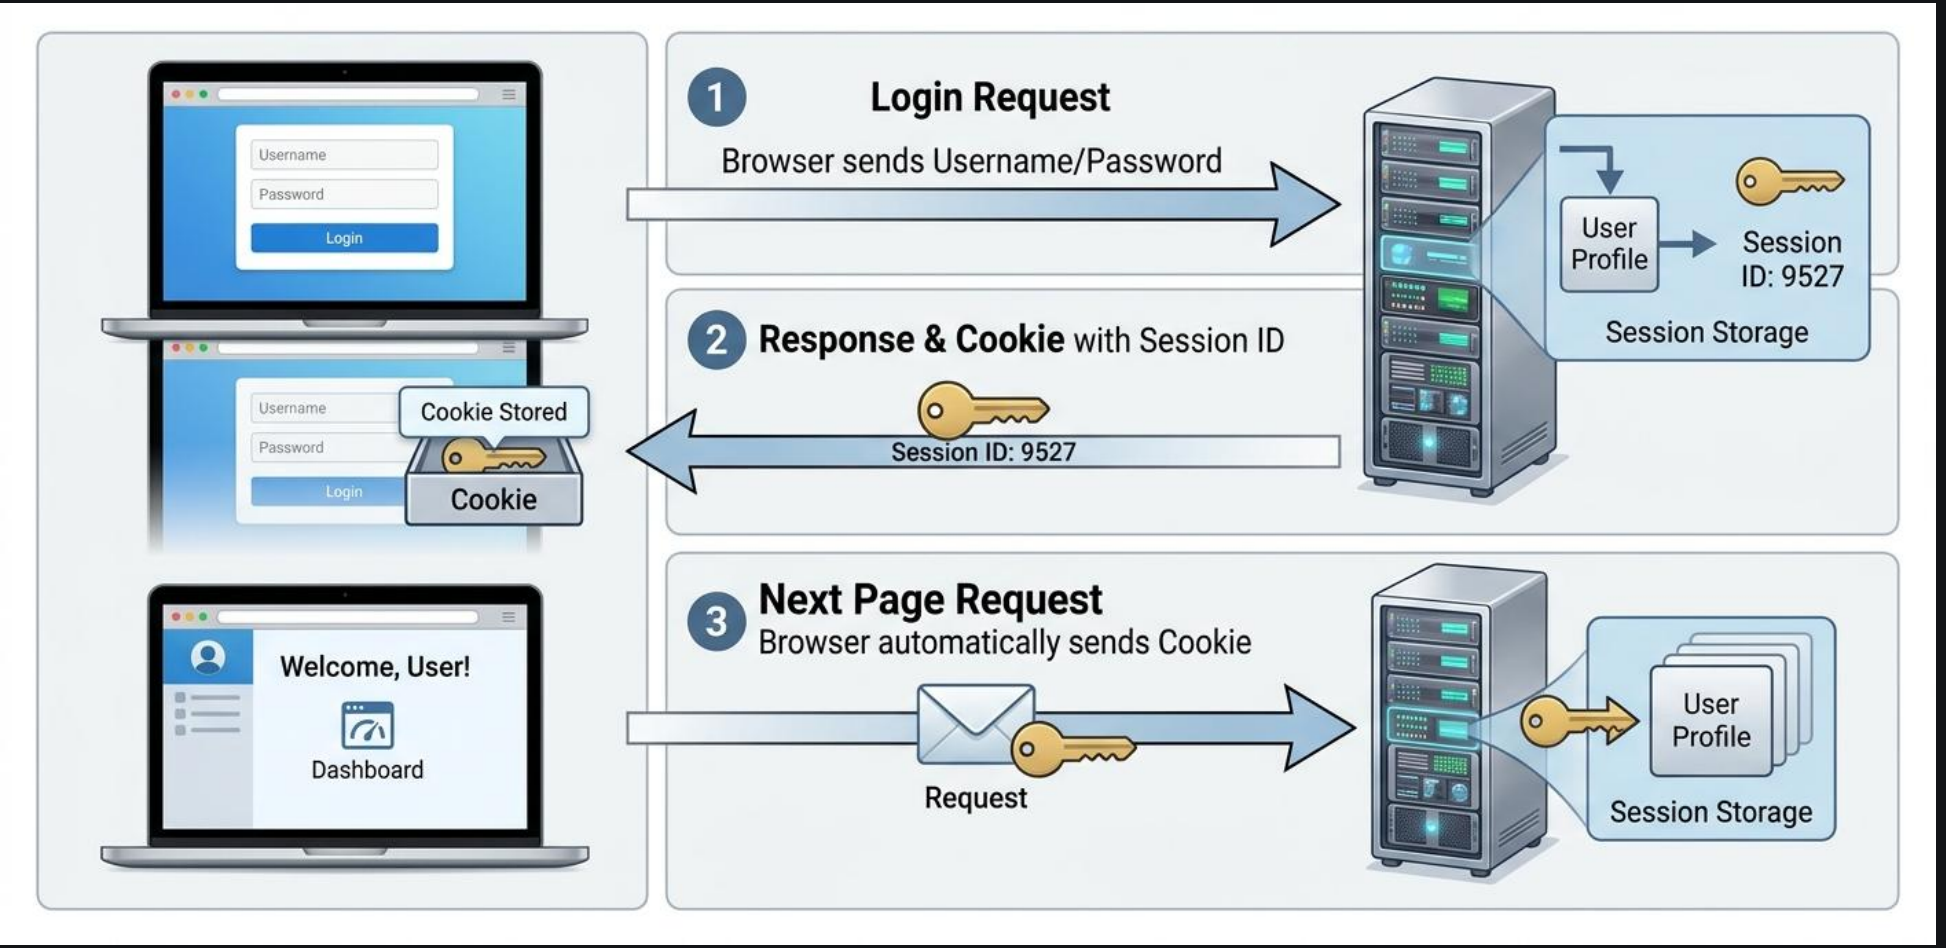
分頁的爬取方法

模式	程式寫法
網址可推算	while 迴圈逐頁爬取
網址帶游標	先找連結的 href，再 urljoin 拼接出完整的網址

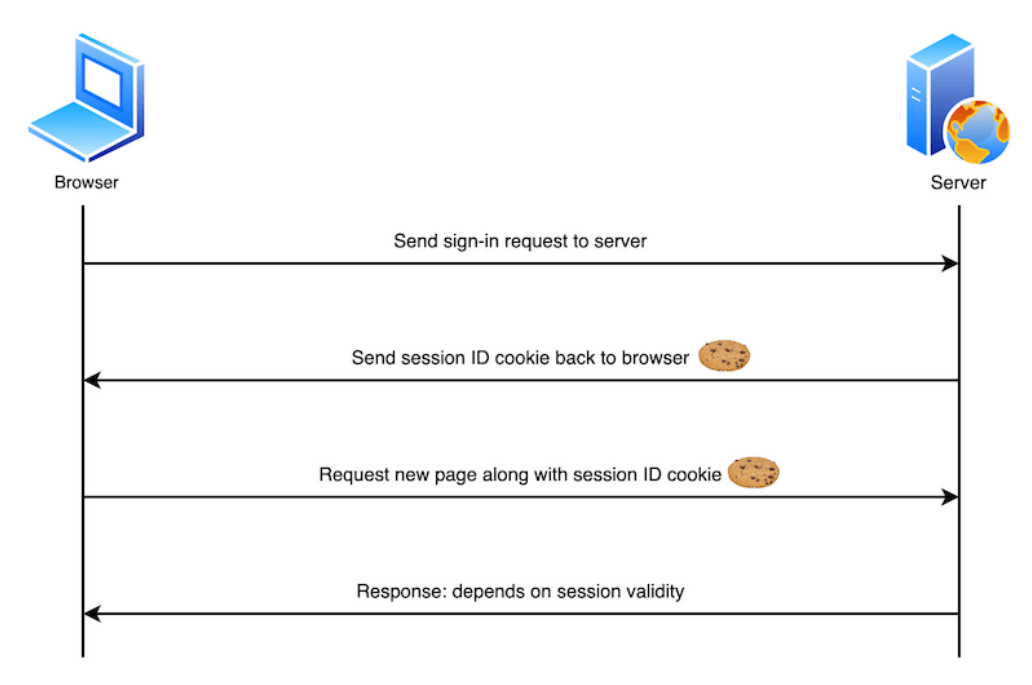


概念　同一網站多頁爬取，翻一頁等於重發一次請求。

如何讓這些請求像是同一個人?



Cookie 是什麼？



- 網頁的核心通訊協定 HTTP/HTTPS 為「**無狀態 Stateless**」的設計，每一次的網頁請求，例如：點擊下一頁、重新整理，在本質上都是完全獨立、互不相識。
- 也就是說，每當我們點擊下一頁或重新整理，網站就會將我們視為陌生人。
- 為了解決這問題，當我們訪問某個網站時，網站的伺服器就會在我們的電腦或手機瀏覽器裡，存下一小段文字檔，這就是 **Cookie**。後續，當再次點擊該網站的任何頁面時，網站依舊能認得出是我們。

參考文件：

- 使用 HTTP Cookie

> **概念**　Cookie 是伺服器發給我們的號碼牌，讓網站能認得出我們。

requests.Session 連續造訪

- 目的 : 用來在多次 HTTP 請求之間**保持跨請求的狀態**

功能	requests.get()	Session
headers	每次請求獨立	設定一次，之後自動帶
cookie	不保存	自動保存、自動帶回
連線	每次重新建立	重複使用，比較快

```
BASE_URL = " .... "
HEADERS = {"User-Agent": "..."}

session = requests.Session()
session.headers.update(HEADERS)

for page in range(1, 11):
    resp = session.get(f"{BASE_URL}/page/{page}/", timeout=10)
    ...
```

概念　同一網站多頁爬取，自動記錄 session 期間所存的 cookie，讓伺服器保留這段 session 的狀態態。

Cookie 與登入

1
GET /login
伺服器發 session cookie
+ 表單藏一個 csrf_token

➜

2
POST /login
送出帳密 + csrf_token
(cookie 要一起帶回)

➜

3
比對配對
token 與 cookie 對得上
→ 登入成功

➜

4
之後的請求
帶著 cookie
→ 看到登入後的內容

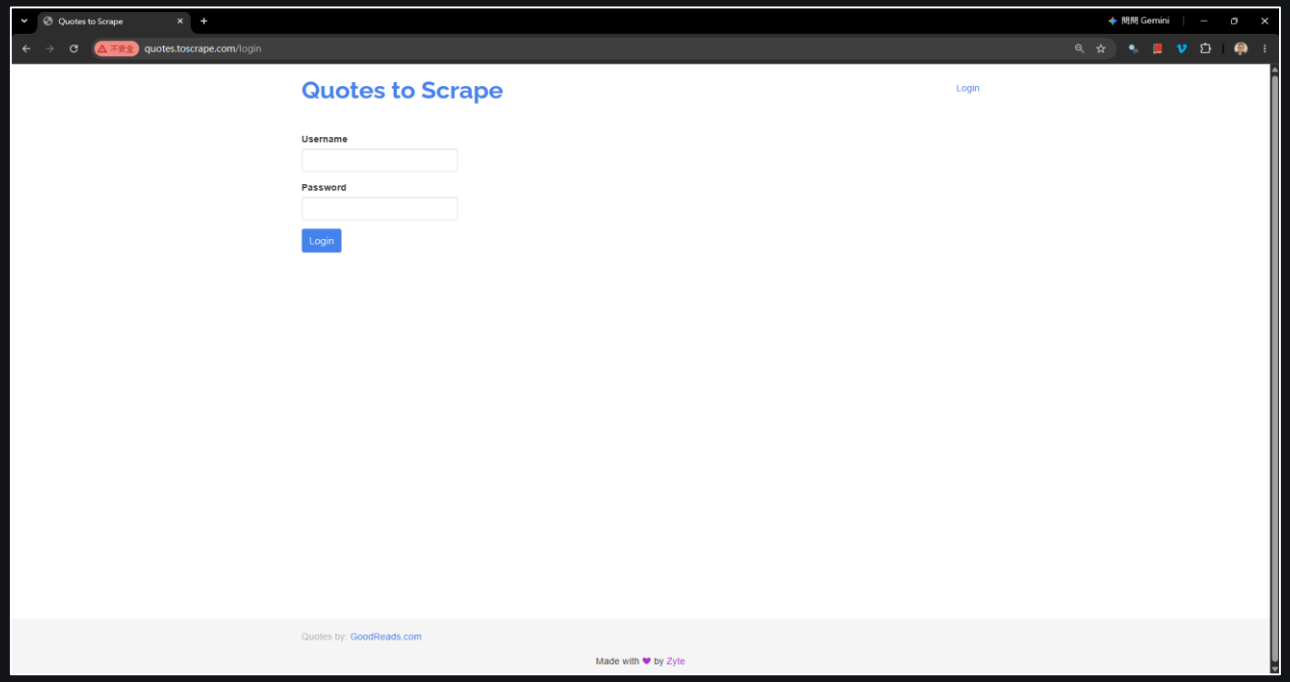
Cookie ? 網站發給我們的數位識別證，可用來辨識使用者身份所設定的資訊。

CSRF Token ? 全名為 Cross-Site Request Forgery Token 跨站請求偽造權杖，是一段由伺服器產生一組獨一無二，且用來驗證網頁請求是否為使用者本人主動發出的隨機字串。

Session 的角色：第 1 步拿到的 cookie，第 2、4 步自動帶回去。

> **概念** Cookie 是伺服器發給我們的號碼牌；Session 幫我們保管號碼牌。

課堂練習 - 2



- 登入 Quotes to Scrape 網站中，爬取第一頁所有的名言，且存成 quotes_all.csv 。
  欄位名稱：page、quote、author、tags

http://quotes.toscrape.com/login

while 迴圈的停止條件?

停止訊號	實際狀況	狀態碼
這一頁沒有資料	quotes 第 11 頁： "No quotes found!"	200
沒有下一頁連結	quotes 第 10 頁、 books 第 50 頁	200
網頁不存在	books page-51.html	404

```
page = 1
while page <= MAX_PAGES:        # 保險絲
    soup = get_soup(f"{BASE}/page/{page}/")
    cards = soup.select("div.quote")
    if not cards:               # 停止條件
        break
    ...
    page += 1
    time.sleep(random.uniform(2, 6))
```

概念　狀態碼 200 不一定代表有資料 - 停止條件也要檢視爬取的內容。

MAX_PAGES 怎麼定？

	停止條件	MAX_PAGES
角色	正常結束	保險絲（最後防線）
預期	每次都由它結束	正常永遠不該碰到
觸發代表	資料抓完了	**出狀況了，要去查**

week_06_exercise_1.py（節錄）

```
if page > MAX_PAGES:     # 不是沒資料而停，是保險絲斷了
    logger.warning("達到 MAX_PAGES=%s，資料可能沒抓完",
                   MAX_PAGES)
```

① 先估總頁數

頁面寫出總頁數：books「Page 1 of 50」
總筆數 ÷ 每頁筆數：1000 ÷ 20 = 50

② 設成估計值 × 2 左右

quotes 10 頁 → 練習設 50；books 50 頁 → 作業設 100
碰到上限 = 多抓了一倍 → 一定有問題

③ 估不出來（如最新列表）→ 用預算定

需求：只要近 7 天？先算一天幾頁
時間：頁數 × 間隔（iThome Crawl-delay 10 秒，100 頁 ≈ 17 分鐘）

概念 MAX_PAGES 是保險絲，不是預計頁數：先估再乘 2；碰到上限要寫 WARNING，不能安靜結束。

拒絕服務攻擊 Denial of Service



- DoS 是指由**單一來源**，例如：同一個 IP 地址、同一台電腦，向伺服器發送大量高頻率的請求，目的在於癱瘓目標伺服器、網路或系統，導致使用者無法存取該服務的網路惡意攻擊。
- 當爬蟲程式用無窮迴圈或極高速度不斷對同一個網站發送 requests 時，在網管系統或防火牆的眼裡，視為「單一 IP 正在進行惡意連線，試圖癱瘓伺服器」。
- 爬蟲被防火牆判定為 DoS 的常見主因
  - 請求頻率過高 Rate Limiting
    一秒鐘內發送了數十次甚至上百次請求，遠超正常人類的點擊速度。
  - 固定發送間隔
    例如：每隔精準的 1 秒就發送一次請求，極度規律的行為一看就知道是機器人。
  - 缺乏或異常的標頭 Header
    請求中沒有帶上 User-Agent，或是帶了預設的 python-requests/2.x，直接暴露是爬蟲程式。

網路禮儀 Netiquette

寫法	對網站的影響
無 sleep( )	易觸發 429 Too Many Requests 警告，進一步 IP 會遭到封鎖 Ban 。
sleep(2)	接近真人瀏覽的速度
robots.txt 有 Crawl-delay	網站明確的要求，建議爬蟲在連續請求之間「等待幾秒鐘」再抓取下一頁，以避免伺服器負載過高

```
import time

...

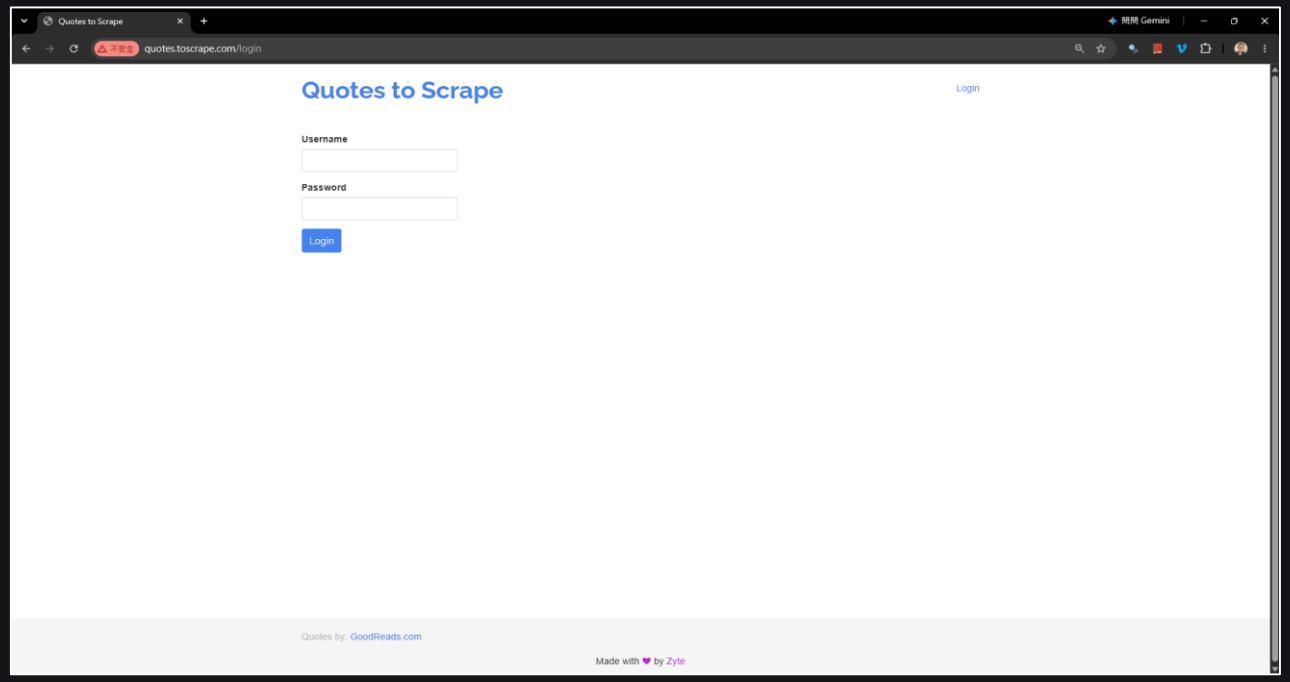
page = 1
while page <= MAX_PAGES:
    ...                          # 逐頁爬取、解析

    page += 1
    time.sleep(random.uniform(2, 6))  # 模擬人的行為
```

迴圈中要避免寫無延遲的無窮迴圈。
每次請求之間，使用 time.sleep(randomuniform(2, 6)) 模擬人類的瀏覽行為，降低被防火牆識別為機器人的風險。

> **概念**　爬得慢一些，可降低對方伺服器的負擔，同時避免被誤偵測為 DoS（拒絕服務攻擊）。

課堂練習 - 3



http://quotes.toscrape.com/login

- 登入 Quotes to Scrape 網站中，爬取第一頁所有的名言，且存成 quotes_all.csv 。
  欄位名稱：page、quote、author、tags
- 另外，利用 logging 記錄爬取過程，記錄每頁抓到幾句名言，將 log 資訊存成 week_06_ex2_Quotes_login.log。

節 2

爬蟲規範

Crawling Ethics & Rules

能不能爬？四道關卡

1

robots.txt

網站對爬蟲的
公開告示

Disallow 明列不能爬取的項目

➜

2

使用條款

Terms of Service

網站與使用者的約定

ToS 為網站提供者所制定的規範文件，旨在明確界定使用者的行為準則，與雙方權利義務，具體涵蓋了內容上傳限制、圖文與商標的授權使用規範等。

➜

3

個人資料

姓名、email、照片...
個資法規範

針對特定自然人的個資保護，例如：台灣個資法、歐盟 GDPR 等。無論前兩關是否允許，只要爬取且利用未經授權的個資，就直接違法。

➜

4

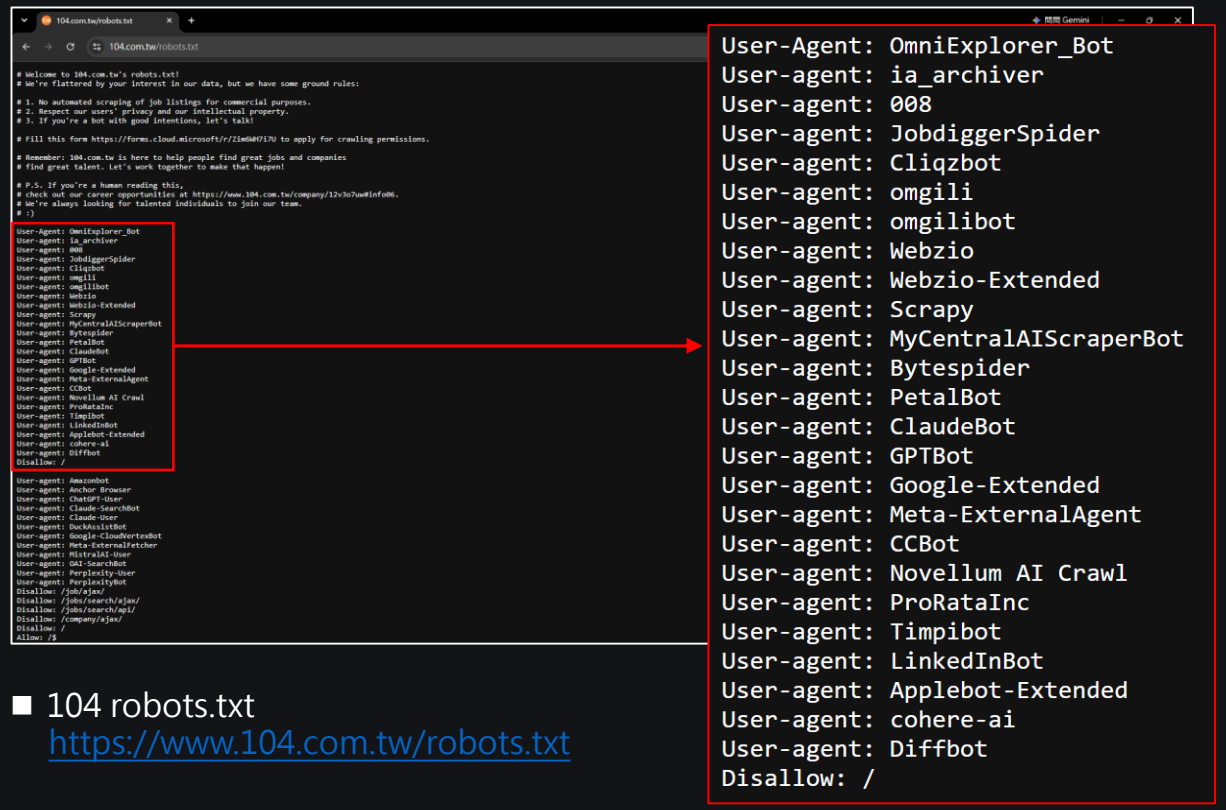
著作權

文章、圖片、評論
不是抓了就能用

最優先原則： 如果有官方開放資料 Open Data 或 API，絕對是合法合規的首選。
只有在沒有 API 的情況下，才去考慮爬取網頁。

> **概念** robots.txt 允許不代表合法 - 涉及個人隱私或他人原創心血，會觸犯個資法與著作權法的底線。

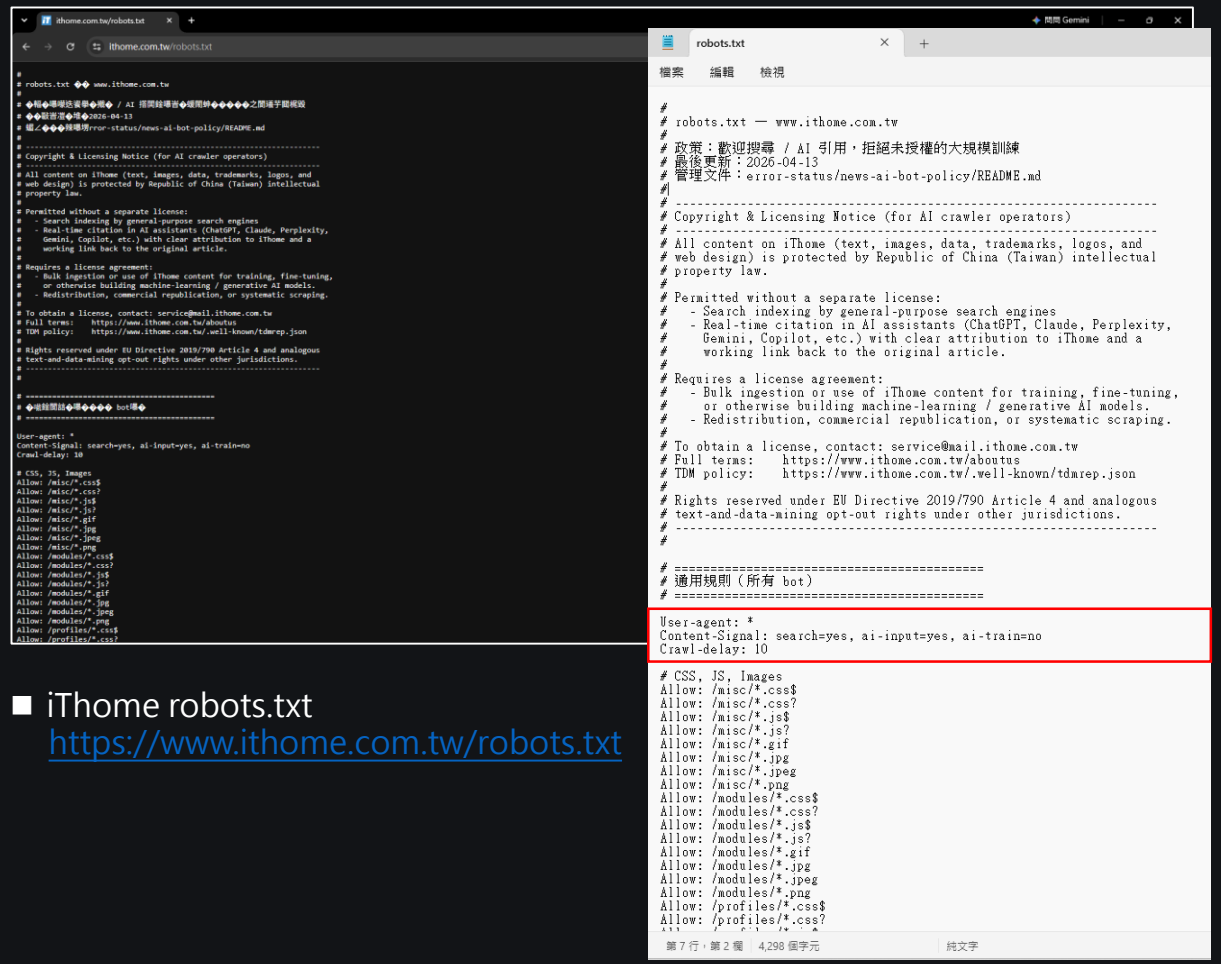
robots.txt 怎麼讀？



- 104 robots.txt
  https://www.104.com.tw/robots.txt

- 在網域後面加 /robots.txt 就能看到。
- User-agent 像是網路爬蟲的名稱標籤，作為宣告接下來的存取規則(允許 Allow、禁止 Disallow)，是專門針對哪一個爬蟲所設定。
- Disallow: / 表示完全禁止指定的機器人，存取該網站的任何內容。
  / 表示網站的根目錄，包含其下的所有網頁與檔案。
- 對於如 GPTBot、ClaudeBot、Google-Extended 等主流 AI 訓練爬蟲與網頁擷取工具，設定為 Disallow: /，完全禁止存取網站的任何內容。

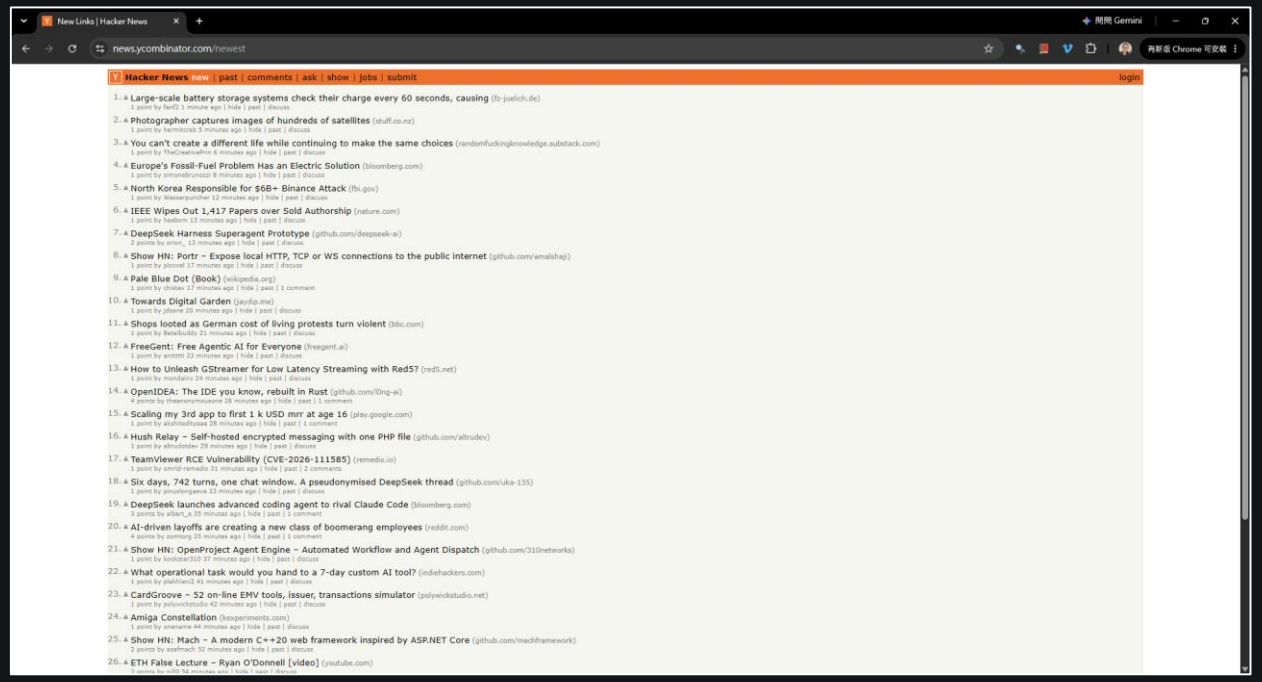
robots.txt - Content-Signal



- iThome robots.txt
  https://www.ithome.com.tw/robots.txt

- 當在瀏覽器開啟 robots.txt 出現亂碼時，係因為瀏覽器沒能正確識 robots.txt 的字元編碼，通常是 UTF-8 編碼誤判所導致。
  建議將 robots.txt 另存新檔儲存到電腦中，再使用記事本或 VS Code 等文字編輯器開啟。
- User-agent: * 表示所有爬蟲，Crawl-delay: 10 表示爬蟲在每次抓取網頁之間，必須暫停等待 10 秒鐘。
- **Content-Signal** 內容訊號政策
  - 2025 年秋季由 Cloudflare 提出的一項擴充協議。
  - 網站經營者能在 robots.txt 檔中，針對 AI 爬蟲明確宣告「抓取內容後的具體用途」。
  - Search 搜尋索引
    是否允許建立搜尋引擎索引、提供搜尋結果(包含連結與簡短摘要，不含 AI 生成的完整摘要）。
  - ai-input（即時 AI 輸入 / 生成回答）
    是否允許即時將網頁內容提供給生成式 AI 作為作答依據，例如：RAG、AI 摘要等。
  - ai-train（AI 模型訓練）
    是否允許將網頁內容用於訓練或微調大型語言模型（LLM）

課堂練習 - 4



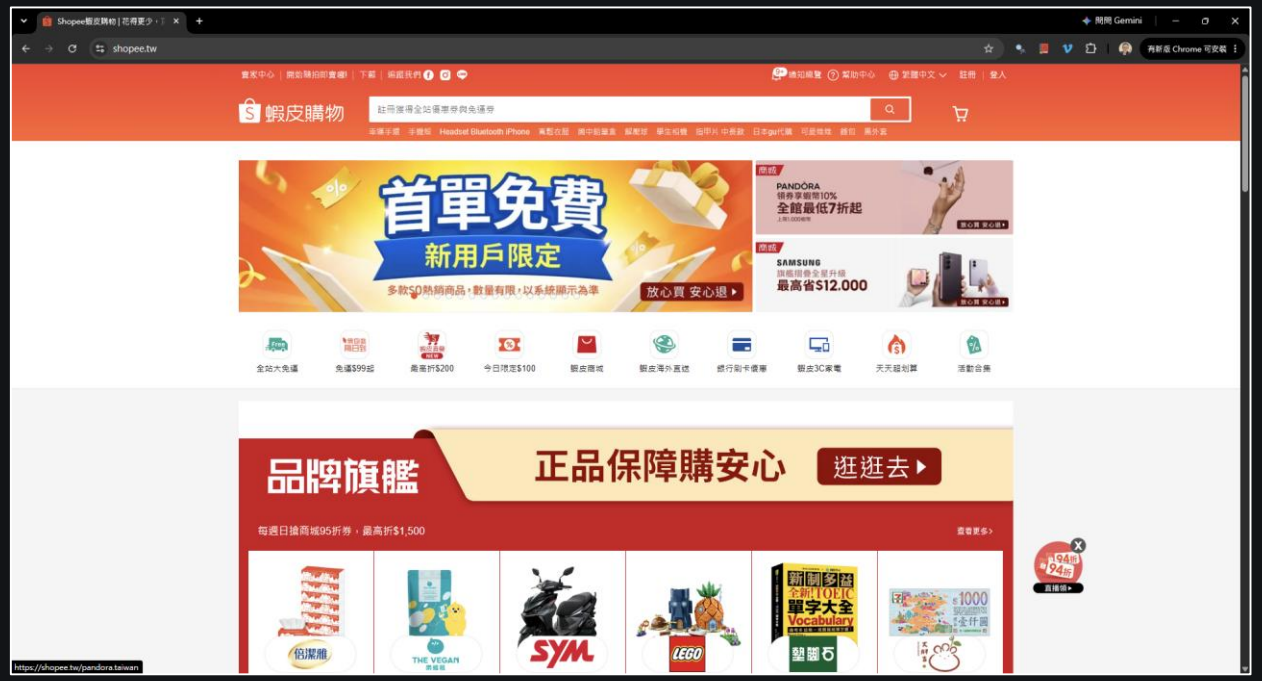
https://news.ycombinator.com/

- 讀取 Hacker News 網站的 robots.txt 檔，請確認下列資訊：

  (1) Crawl-delay 是幾秒？

  (2) User-agent: * 明確標示哪些禁止項目？

課堂練習 - 5



https://shopee.tw/

- 讀取蝦皮購物網站的 robots.txt 檔，請確認下列資訊：
  (1) 一般爬蟲的 Crawl-delay 是幾秒？
  (2) Googlebot 的 Crawl-delay 是幾秒？

課堂練習 - 6



https://www.moneydj.com/

- 讀取 MoneyDJ 理財網站的 robots.txt 檔，請確認下列資訊：

  (1) 一般爬蟲明確標示允許有幾項？

  (2) 這份 robots.txt 全面封鎖多種特定爬蟲，且列舉出針對 AI 模型訓練被封鎖的爬蟲名稱。

課堂練習 - 7



https://www.books.com.tw/

- 讀取博客來網站的 robots.txt 檔，請確認下列資訊：

  (1) User-agent: GPTBot 明確標示哪些禁止項目？

  (2) User-agent: * 明確標示哪些禁止項目？

  (3) Content-Signal 的規範
  - search = ?
  - ai-train = ?

Request for Comments

- RFC 9309 正式將大家自 1994 年以來約定俗成的 robots.txt ，給予官方的標準化定義與規格。
- RFC 9309 是由網際網路工程任務組 IETF，在 2022 年 9 月正式發布網際網路標準 Proposed Standard，其正式名稱為 Robots Exclusion Protocol 機器人排除協定。
- **基礎宣告與格式限制**
  - 檔案路徑與命名：檔案必須存放在**網站的根目錄下**，且**檔名必須完全小寫**，即 /robots.txt。
  - 編碼格式：規定必須使用 **UTF-8** 純文字格式。
  - 大小限制：解析器(parser)最少必須能處理 500 KiB 以上的檔案大小。
- **語法比對規則**
  - 群組解析：爬蟲會尋找符合自身名稱(不分大小寫)的 User-agent 區塊。如果找不到，則會 fallback 使用萬用字元 * 的區塊。
  - 最長路徑優先：當同一個群組內同時存在 Allow 與 Disallow 規則且產生衝突時，解析器會以路徑長度最長（最具體、位元組最多）的規則為準。如果長度完全相同，則通常會優先採用 Allow。
- RFC 9309 未納入的標準
  - Crawl-delay：限制爬蟲抓取頻率的延遲宣告
  - Sitemap：網站地圖宣告

用 Python 解析 robots.txt

方法	用途
set_url( )	指定 robots.txt 位置（要寫到 /robots.txt ）
read( )	下載且解析 robots.txt
can_fetch(UA, 網址)	判斷某個 User-Agent 能不能爬取某個網址 → True / False
crawl_delay(UA)	請求間隔秒數。 若無明確宣示，則回 None。

```python
from urllib import robotparser

# 初始化解析器
rp = robotparser.RobotFileParser( )

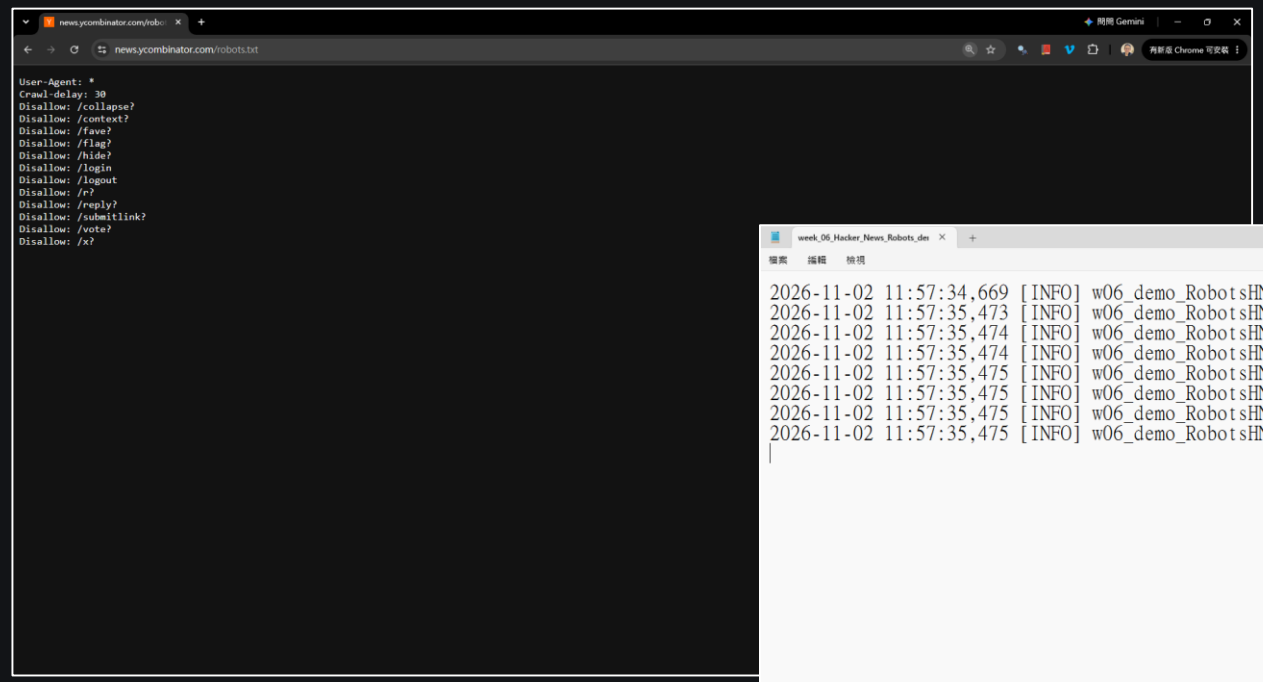
# 設定 robots.txt 路徑位置
rp.set_url("https://news.ycombinator.com/robots.txt")

# 下載且解析 robots.txt
rp.read()

# 判斷 UA 能否爬取
rp.can_fetch("MyCustomBot",
                "https://news.ycombinator.com/newest"
)

# 請求的間隔時間(秒)
rp.crawl_delay("MyCustomBot")     # 30
```

Python 解析 Hacker News 的 robots.txt



week_06_Hacker_News_robots_demo.py



課堂練習 - 8



https://www.ithome.com.tw/robots.txt

- 解析 iThome 的 robots.txt ，完成下列資訊檢視：

(1) 下列網址 MyCustomBot 能否爬取？

"首頁": "https://www.ithome.com.tw/",

"最新新聞": "https://www.ithome.com.tw/latest",

"單篇新聞": "https://www.ithome.com.tw/news/171234",

"站內搜尋": "https://www.ithome.com.tw/search/python",

"會員登入": "https://www.ithome.com.tw/user/login/",

"CSS 檔": "https://www.ithome.com.tw/misc/a.css"

(2) Crawl-delay 幾秒？

(3) 下列網址 GPTBot 與 ClaudeBot 能否爬取？

"最新新聞": "https://www.ithome.com.tw/latest"

課堂練習 - 8



```
#
# robots.txt — www.ithome.com.tw
#
# 政策：歡迎搜尋 / AI 引用，拒絕未授權的大規模訓練
# 最後更新：2026-04-13
# 管理文件：error-status/news-ai-bot-policy/README.md
#
# ------------------------------------------------------------------
# Copyright & Licensing Notice (for AI crawler operators)
# ------------------------------------------------------------------
# All content on iThome (text, images, data, trademarks, logos, and
# web design) is protected by Republic of China (Taiwan) intellectual
# property law.
#
# Permitted without a separate license:
#   - Search indexing by general-purpose search engines
#   - Real-time citation in AI assistants (ChatGPT, Claude, Perplexity,
#     Gemini, Copilot, etc.) with clear attribution to iThome and a
#     working link back to the original article.
#
# Requires a license agreement:
#   - Bulk ingestion or use of iThome content for training, fine-tuning,
#     or otherwise building machine-learning / generative AI models.
#   - Redistribution, commercial republication, or systematic scraping.
#
# To obtain a license, contact: service@mail.ithome.com.tw
# Full terms:    https://www.ithome.com.tw/aboutus
# TDM policy:    https://www.ithome.com.tw/.well-known/tdmrep.json
#
# Rights reserved under EU Directive 2019/790 Article 4 and analogous
# text-and-data-mining opt-out rights under other jurisdictions.
# ------------------------------------------------------------------
#


# ============================================
# 通用規則（所有 bot）
# ============================================

User-agent: *
Content-Signal: search=yes, ai-input=yes, ai-train=no
Crawl-delay: 10

# CSS, JS, Images
Allow: /misc/*.css$
Allow: /misc/*.css?
Allow: /misc/*.js$
Allow: /misc/*.js?
Allow: /misc/*.gif
Allow: /misc/*.jpg
Allow: /misc/*.jpeg
Allow: /misc/*.png
Allow: /modules/*.css$
Allow: /modules/*.css?
Allow: /modules/*.js$
Allow: /modules/*.js?
Allow: /modules/*.gif
Allow: /modules/*.jpg
Allow: /modules/*.jpeg
Allow: /modules/*.png
Allow: /profiles/*.css$
Allow: /profiles/*.css?
```

https://www.ithome.com.tw/robots.txt

- 解析 iThome 的 robots.txt ，完成下列資訊檢視：

  (4) 檢視是否有 Content-Signal 的資訊？

  - 若有宣告，寫在哪個 User-agent 群組中？且宣告那些訊號？

被擋了怎麼辦？

狀態碼	狀態說明	爬蟲該怎麼做
503 Service Unavailable	目標伺服器暫時無法處理請求，通常因流量太大超載、網站正在維護等所導致。	勿立刻連續地重新發送請求! 先等待，且逐步拉長等待時間再重試。
429 Too Many Requests	目標伺服器拒絕短時間內的多個請求。如果繼續發請求，很可能變成 403 ，甚至 IP 遭永久封鎖 Block。	遵守 unset Retry-After 秒數；若沒有，則，設置 4、6、8 、.... 秒等待重試。
403 Forbidden	目標伺服器理解我們的請求，但，因權限或安全機制，不准我們進去，拒絕授權存取。	不再重試，先檢視 robots.txt、使用條款等，是否需要授權?
404 Not Found	成功連接到目標伺服器，伺服器收到我們的請求，但，網址 URL 在伺服器上並不存在。	檢查網址拼接是否正確?

今天，我們學到了什麼？

下週見 · Python 爬蟲實務應用